

데이터 분석 프로젝트 계획 보고서

조 / 이름	
제출일	
데이터셋 이름	
캐글 URL	

분량은 A4 1장. 칸을 채우는 것보다 **왜**를 적는 게 중요합니다. 아직 분석을 돌릴 필요는 없습니다. 데이터를 열어보고 앞으로 무엇을 할지 말할 수 있으면 충분합니다.

1. 어떤 데이터인가

원본 출처	예: WHO 공개통계 / 타인 재업로드 / 합성(synthetic·generated) 여부
데이터 크기	예: 행 ____ × 열 ____
파일 구성	예: train.csv 1개 / 3개 파일 조인 필요

원본 출처 칸을 비워두지 마세요. 캐글에는 남의 데이터를 재업로드한 것, 통계적으로 합성한 가짜 데이터가 섞여 있습니다.

합성 데이터라도 연습용으로 쓸 수는 있습니다. 대신 “여기서 찾은 관계는 실제 세계의 관계가 아니다”라는 사실을 알고 시작해야 합니다.

데이터 설명(Description) 페이지에 synthetic, generated, simulated 같은 단어가 있는지 확인하세요.

2. 왜 이 데이터인가

- **계기** (2~3문장):
- **비교한 다른 데이터셋 후보** — 최소 하나 이상. 처음 검색해서 나온 걸 그대로 쓰면 대개 나중에 후회합니다. 2~3가지 이상의 비슷한 데이터 셋을 검색해 보고 선정하는 것이 좋습니다.

후보 데이터셋	제외한 이유
예: Heart Disease UCI	303행뿐이라 분할하면 검증셋이 너무 작음

- **고른 이유**: “깨끗해서”(×) → 답하려는 질문에 필요한 변수가 실제로 들어 있는가?

3. 무엇을 분석할 것인가

- 한 문장 요약: _____으로 _____을(를) 예측한다 / 분류한다 / 집단으로 나눈다
- 핵심 질문:
- 문제 유형: ☐ 회귀 ☐ 분류 ☐ 군집 ☐ 시계열
- 목표변수 Y: 컬럼명 _____ / 척도 _____
- 설명변수 X 표

컬럼명	의미 · 단위	Y와 관련 있다고 보는 이유

핵심 질문은 데이터로 답이 나오는 형태로 작성합니다.

- “청소년 우울증을 어떻게 해결할까”(×) - “수면시간이 짧은 집단에서 우울 점수가 더 높게 나타나는가”(○)

빠뜨리기 쉬운 것이 **X와 Y 양쪽에 영향을 주는 변수**입니다. 아이스크림 판매량과 익사 사고 수는 같이 올라가지만 둘 다 기온 때문입니다. 그런 변수가 데이터에 있다면 표에 넣으세요.

4. 데이터 실물 확인

행 × 열	결측 많은 컬럼	이상한 값	Y 분포
	예: income 34% 결측	예: 나이 999, 소득 -1	

다운로드 후 `head()` / `info()` / `describe()` 등으로 간단히 생김세를 확인해 보세요. 데이터의 모습을 확인하지 않은 상태로 주제를 확정하면 분석 과정에서 데이터의 상태에 따라 주제를 변경하거나 포기하게 됩니다. 아직 전처리는 하지 않습니다.

무응답을 9, 99, 999로 코딩해둔 데이터가 흔합니다. 숫자로 읽히니 오류처럼 안 보이지만 그대로 두면 평균이 망가집니다. `describe()`의 최댓값이 유난히 크면 의심해보세요.

5. 수행 계획

• 1주차

-
-
-

• 2주차

-
-
-

• 3주차

-
-
-

필요하다면 기간을 더 늘려 잡을 수 있습니다.